

# 模式识别作业 1-6

周圣威 1120213587

June 2024

## 1 作业1

已知权重矩阵  $W$  (大小为  $n \times n$ ) 和向量  $Q$  (大小为  $n \times 1$ ) , 以及辅助矩阵  $D$ 。其中,  $D$  是  $W$  的度矩阵 (即  $D$  的对角元素是  $W$  每一行的元素和)。

首先, 考虑表达式  $\sum_{i,j} w_{ij}(q_i - q_j)^2$ 。

展开该公式, 得

$$\sum_{i,j} w_{ij}(q_i - q_j)^2 = \sum_{i,j} w_{ij}(q_i^2 - 2q_i q_j + q_j^2)$$

将求和分解开, 上式可变为

$$\sum_{i,j} w_{ij} q_i^2 - 2 \sum_{i,j} w_{ij} q_i q_j + \sum_{i,j} w_{ij} q_j^2$$

由于上课老师并未提到  $W$  是否为对称矩阵, 故做如下分类。

### 1.1 $W$ 不是对称矩阵

我们可以合并这些项

$$\sum_i q_i^2 \sum_j w_{ij} - 2 \sum_{i,j} w_{ij} q_i q_j + \sum_j q_j^2 \sum_i w_{ij}$$

注意到  $\sum_j w_{ij}$  实际上是  $W$  对应的度矩阵  $D_1$  的对角元素  $d_i$  ,  $\sum_i w_{ij}$  实际上是  $W^T$  对应的度矩阵  $D_2$  的对角元素  $d_j$  , 可得

$$\sum_i d_i q_i^2 - 2 \sum_{i,j} w_{ij} q_i q_j + \sum_j d_j q_j^2$$

用矩阵的形式表示, 可以表示为

$$Q^T D_1 Q - 2Q^T W Q + Q^T D_2 Q$$

最终结果为

$$\sum_{i,j} w_{ij}(q_i - q_j)^2 = Q^T D_1 Q - 2Q^T W Q + Q^T D_2 Q$$

## 1.2 $W$ 是对称矩阵

同样合并这些项，得

$$\sum_i q_i^2 \sum_j w_{ij} - 2 \sum_{i,j} w_{ij} q_i q_j + \sum_j q_j^2 \sum_i w_{ij}$$

由于  $W$  是对称的矩阵（即  $w_{ij} = w_{ji}$ ），注意到第一项和第三项实际上是相同的，因为它们都表示  $q_i$  和  $q_j$  被权重和相应的项所权重后的平方和

$$\sum_i q_i^2 \sum_j w_{ij} - 2 \sum_{i,j} w_{ij} q_i q_j + \sum_i q_i^2 \sum_j w_{ij}$$

进一步简化，注意到  $\sum_j w_{ij}$  实际上是度矩阵  $D$  的对角元素  $d_i$

$$2 \sum_i d_i q_i^2 - 2 \sum_{i,j} w_{ij} q_i q_j$$

用矩阵的形式表示，可以表示为

$$2Q^T D Q - 2Q^T W Q$$

最终结果为

$$\sum_{i,j} w_{ij} (q_i - q_j)^2 = 2Q^T D Q - 2Q^T W Q$$

上课时老师说用  $W$ 、 $Q$ 、 $D$  表示， $W$  能推出  $D$ ，所以感觉应该是默认  $W$  是对称矩阵了。

## 2 作业2

考虑一个二分类问题，类的先验分布和似然概率分别如下：

先验分布：  $P(\omega_1) = 0.6$ 、 $P(\omega_2) = 0.4$

似然概率： 对于类  $\omega_1$ ：

$$p(x|\omega_1) = \begin{cases} x & 0 \leq x < 1 \\ 2 - x & 1 \leq x \leq 2 \\ 0 & \text{else} \end{cases}$$

对于类  $\omega_2$ ：

$$p(x|\omega_2) = \begin{cases} x - 1 & 1 \leq x < 2 \\ 3 - x & 2 \leq x \leq 3 \\ 0 & \text{else} \end{cases}$$

已知 MAP 分类准则的公式为

$$\text{MAP}(x) = \arg \max_i P(\omega_i|x)$$

根据贝叶斯公式，后验概率可以表示为：

$$P(\omega_i|x) = \frac{p(x|\omega_i)P(\omega_i)}{p(x)}$$

其中， $p(x)$  是样本  $x$  的边际概率，可得

$$p(x) = p(x|\omega_1)P(\omega_1) + p(x|\omega_2)P(\omega_2)$$

当  $x = 1.6$  时，有

似然概率为

$$p(1.6|\omega_1) = 2 - 1.6 = 0.4$$

$$p(1.6|\omega_2) = 1.6 - 1 = 0.6$$

边际概率为

$$p(1.6) = p(1.6|\omega_1)P(\omega_1) + p(1.6|\omega_2)P(\omega_2)$$

$$p(1.6) = 0.4 \times 0.6 + 0.6 \times 0.4 = 0.24 + 0.24 = 0.48$$

后验概率为

$$P(\omega_1|1.6) = \frac{p(1.6|\omega_1)P(\omega_1)}{p(1.6)} = \frac{0.4 \times 0.6}{0.48} = \frac{0.24}{0.48} = 0.5$$

$$P(\omega_2|1.6) = \frac{p(1.6|\omega_2)P(\omega_2)}{p(1.6)} = \frac{0.6 \times 0.4}{0.48} = \frac{0.24}{0.48} = 0.5$$

在这种情况下，后验概率是相同的，即  $P(\omega_1|1.6) = P(\omega_2|1.6)$ ，即我们无法根据MAP分类准则直接确定样本  $x = 1.6$  的类别。因此可以选择一个策略，例如选择具有较高先验概率的类，即  $\omega_1$ 。

所以，给定输入样本  $x = 1.6$ ，我们可以将其分类为类  $\omega_1$ 。

### 3 作业3

已知随机变量  $x$  服从拉普拉斯分布，其概率密度函数为

$$f(x|\mu, \lambda) = \frac{1}{2\lambda} \exp\left(-\frac{|x - \mu|}{\lambda}\right)$$

同时已知尺度参数  $\lambda$ 。

首先找到使得似然函数最大的  $\mu$  值。令似然函数  $L(\mu)$  为

$$L(\mu) = \prod_{i=1}^N f(x_i|\mu, \lambda)$$

将拉普拉斯分布的概率密度函数代入：

$$L(\mu) = \prod_{i=1}^N \frac{1}{2\lambda} \exp\left(-\frac{|x_i - \mu|}{\lambda}\right)$$

取对数似然函数  $\ell(\mu)$ ：

$$\ell(\mu) = \ln L(\mu) = \sum_{i=1}^N \ln\left(\frac{1}{2\lambda} \exp\left(-\frac{|x_i - \mu|}{\lambda}\right)\right)$$

$$\ell(\mu) = \sum_{i=1}^N \left(\ln\left(\frac{1}{2\lambda}\right) - \frac{|x_i - \mu|}{\lambda}\right)$$

$$\ell(\mu) = N \ln\left(\frac{1}{2\lambda}\right) - \frac{1}{\lambda} \sum_{i=1}^N |x_i - \mu|$$

为了最大化  $\ell(\mu)$ ，我们需要最小化  $\sum_{i=1}^N |x_i - \mu|$ ，即找到这组数的中位数。即位置参数  $\mu$  的最大似然估计是样本  $x_i$  的中位数。

所以，当已知尺度参数  $\lambda$  时，拉普拉斯分布位置参数  $\mu$  的最大似然估计为样本数据的中位数。

## 4 作业4

首先初始化高斯成分的参数 $\mu_c$ 、 $\sigma_c$ 和 $w_c$ ，其中 $\mu_c$ 是均值， $\sigma_c$ 是协方差矩阵， $w_c$ 是每个成分 $c$ 的混合系数。

在 E 步，计算每个高斯成分 $c$ 对每个数据点 $x_i$ 的权重

$$\gamma_{ic} = \frac{w(c)\mathcal{N}(x_i|\mu_c, \sigma_c)}{\sum_{c=1}^C w(c)\mathcal{N}(x_i|\mu_c, \sigma_c)}$$

其中 $\mathcal{N}(x_i|\mu_c, \sigma_c)$ 是第 $c$ 个高斯成分的概率密度函数。

在 M 步，使用在 E 步中计算的权重来更新参数，得

$$w(c) = \frac{N_c}{N}$$

$$\mu_c = \frac{1}{N_c} \sum_{i=1}^N \gamma_{ic} x_i$$

$$\sigma_c = \frac{1}{N_c} \sum_{i=1}^N \gamma_{ic} (x_i - \mu_c)(x_i - \mu_c)^T$$

其中 $N_c = \sum_{i=1}^N \gamma_{ic}$ 是分配给簇 $c$ 的有效点数。

最后我们进行评估，给定当前参数的数据的对数似然如下

$$\log L(\theta) = \sum_{i=1}^N \log \left( \sum_{c=1}^C w(c)\mathcal{N}(x_i|\mu_c, \sigma_c) \right)$$

如果对数似然的变化低于某个阈值，则算法已收敛。否则，返回到 E 步。

## 5 作业5

---

**Algorithm 1** 椭圆K-means算法

---

**Require:** 数据集  $X$ , 簇的数量  $K$ , 最大迭代次数  $max\_iters$

**Ensure:** 簇中心  $\mu$ , 簇分配标签  $labels$

```
1: 初始化:
2:   随机选择  $K$  个数据点作为初始簇中心  $\mu[k]$ ,  $k = 1, \dots, K$ 
3:   初始化每个簇的协方差矩阵  $S[k]$  为单位矩阵
4: repeat
5:   簇分配步骤:
6:   for 每个数据点  $x[i]$  do
7:     计算  $x[i]$  到每个簇中心  $\mu[k]$  的椭圆距离  $d(x[i], \mu[k]) =$   

 $\sqrt{(x[i] - \mu[k])^T S[k]^{-1} (x[i] - \mu[k])}$ 
8:     将  $x[i]$  分配到最近的簇  $j$ :  $labels[i] = \arg \min_k d(x[i], \mu[k])$ 
9:   end for
10:  簇中心更新步骤:
11:  for 每个簇  $k$  do
12:    更新簇中心  $\mu[k] =$  簇  $k$  中所有数据点的均值
13:  end for
14:  协方差矩阵更新步骤:
15:  for 每个簇  $k$  do
16:    计算新的协方差矩阵  $S[k] =$  簇  $k$  中所有数据点的协方差矩阵
17:  end for
18: until 簇分配不再改变或达到最大迭代次数
19: return 簇中心  $\mu$  和簇分配标签  $labels$ 
```

---

## 6 作业6

---

**Algorithm 2** 用竞争学习算法实现RBF网络的训练

---

**Require:** 数据集  $X$ , 输出标签  $Y$ , 隐藏层节点数目  $K$ , 最大迭代次数  $max\_iters$ , 学习率  $\eta$

**Ensure:** 隐藏层中心  $C$ , 隐藏层宽度  $\sigma$ , 输出层权重  $W$

```
1: 初始化:
2:   随机选择  $K$  个数据点作为初始中心  $C[k]$ ,  $k = 1, \dots, K$ 
3: for 迭代次数  $t$  从 1 到  $max\_iters$  do
4:   for 每个输入数据点  $x[i]$  do
5:     计算  $x[i]$  到每个中心  $C[k]$  的欧氏距离  $d(x[i], C[k])$ 
6:     找到最近的中心  $j$ :  $j = \arg \min_k d(x[i], C[k])$ 
7:     更新最近中心  $j$ :  $C[j] = C[j] + \eta \cdot (x[i] - C[j])$ 
8:   end for
9: end for
10: 计算宽度:
11: for 每个中心  $C[k]$  do
12:   计算簇  $k$  中所有点到中心  $C[k]$  的平均距离
13:   设置  $\sigma[k] = \text{平均距离}$ 
14: end for
15: 调整输出层权重:
16: 计算隐藏层输出矩阵  $\Phi$ , 其中  $\Phi[i, k] = \exp\left(-\frac{\|x[i] - C[k]\|^2}{2\sigma[k]^2}\right)$ 
17: 使用最小二乘法求解权重  $W$ :  $W = (\Phi^T \Phi)^{-1} \Phi^T Y$ 
18: return 隐藏层中心  $C$ , 宽度  $\sigma$  和输出层权重  $W$ 
```

---